Proiect Învățare Automată

Titlu tema: Heart Failure Prediction – Prezicerea bolilor de inima



Student: Draghici Andreea-Maria

Grupa: CR4.S1 A Anul de studiu: IV

Specializarea: Calculatoare Romana

Link problema: https://www.kaggle.com/datasets/andrewmvd/heart-failure-clinical-data?page=2

Stim cu totii ca bolile cardiovasculare sunt cauza numarul 1 de deces la nivel global. Mi-am dorit sa analizez acest topic, pentru a vedea ce rezultate pot obtine.

Initial am importat in Jupyter librariile si datasetul pentru a il incarca si citii datele din el.

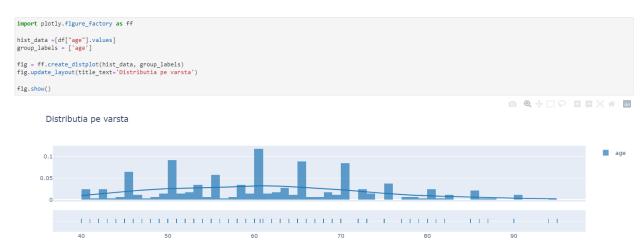
```
#importare librarii
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
sns.set(style='darkgrid')
import warnings
warnings.filterwarnings('ignore')
#importare functii
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import LabelEncode
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import StratifiedKFold
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
\textbf{from} \  \, \textbf{sklearn.neighbors} \  \, \textbf{import} \  \, \textbf{KNeighborsClassifier}
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.naive_bayes import GaussianNB
from sklearn.svm import SVC
\label{thm:cond} $$ df-pd.read\_csv("C:\sers\ser') $$ in care $ datasetul $ si $il $ citesc $ lift $$ it $ citesc $ lift $$ of the serious $ lift $
```

Pentru acest lucru, pe baza unui dataset, am utilizat mai multe metode pentru a obtine statistici representative ca mai jos. Pentru a vedea procentul deceselor si al bolii decesului atat la femei, cat si la barbati.

```
human_df = df.copy()
human_df["diabetes"] = human_df["diabetes"].replace(0, "non-diabetes")
human_df["diabetes"] = human_df["diabetes"].replace(1, "diabetes")
human_df["sex"] = human_df["sex"].replace(0, "male")
human_df["sex"] = human_df["sex"].replace(1, "female")
human_df["smoking"] = human_df["smoking"].replace(0, "non-smoking")
human_df["smoking"] = human_df["smoking"].replace(1, "smoking")
human_df["DEATH_EVENT"] = human_df["DEATH_EVENT"].replace(0, "dead")
human_df["DEATH_EVENT"] = human_df["DEATH_EVENT"].replace(1, "alive")
fig = px.sunburst(
    human_df,
    path=['sex', 'smoking', 'diabetes', 'DEATH_EVENT'],
)
fig.show()
```



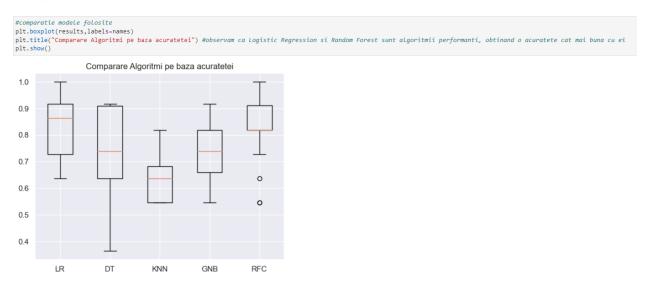
Pe baza atributului age, am dorit sa vad o distributie pe varsta a deceselor.



Am impartit datele pentru antrenament si test, apoi am evaluat modelele pentru a obtine acuratetea.

```
#separam variabila de raspuns din setul de date
X=df.drop('DEATH_EVENT',axis=1)
y=df['DEATH_EVENT']
#datele de antrenament
X train, X val, y train, y val = train test split(X, y, test size=0.25, random state=2)
#modelele
models=[]
models.append(('LR',LogisticRegression(solver='liblinear',multi class='ovr')))
models.append(('DT',DecisionTreeClassifier()))
models.append(('KNN',KNeighborsClassifier()))
models.append(('GNB',GaussianNB()))
models.append(('RFC',RandomForestClassifier()))
#evaluarea modelului
results=[]
names=[]
for name, model in models:
    kfold=StratifiedKFold(n_splits=20)#random_state=1
    cv_results=cross_val_score(model, X_train, y_train, cv=kfold, scoring='accuracy')
    results.append(cv results)
    names.append(name)
    print(' %s: Acuratete: %f' %(name,cv_results.mean()))
 LR: Acuratete: 0.838258
 DT: Acuratete: 0.743561
 KNN: Acuratete: 0.638258
 GNB: Acuratete: 0.753409
 RFC: Acuratete: 0.824621
```

Apoi am comparat algoritmii folositi in functie de acuratetea obtinuta anterior si am observat ca cei mai performanti algoritmi sunt Logistic Regression si Random Forest Classifier.



Apoi pentru cei doi algoritmi vom antrena modelele, datele de test si antrenament, pentru a obtine acuratetea intre valorile de test si cele prezise.

In final am vrut sa am un raport general asupra datasetului si astfel pe baza unei librarii importate, am putut genera un raport sub format html.

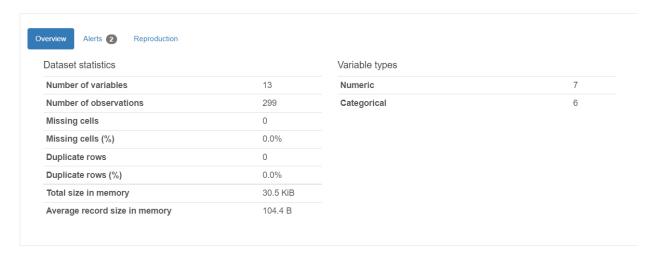
```
from pandas_profiling import ProfileReport

profile = ProfileReport(df, title="General Report")
profile.to_file("general_report.html")

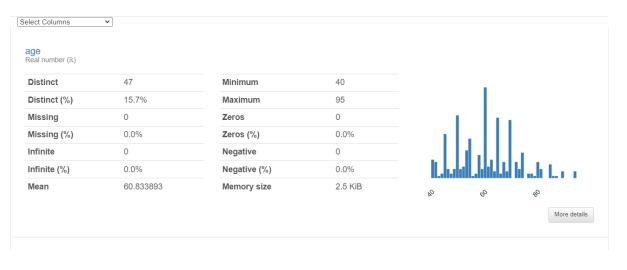
profile
```

Rezultate:

Overview



Variables



Referinte

- 1. https://www.kaggle.com/datasets/andrewmvd/heart-failure-clinical-data
- 2. https://bmcmedinformdecismak.biomedcentral.com/articles/10.1186/s12911-020-1023-5
- 3. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5863635/
- 4. https://www.kaggle.com/datasets/andrewmvd/heart-failure-clinical-data/discussion
- 5. https://www.kaggle.com/datasets/andrewmvd/heart-failure-clinical-data/discussion/181241?page=2

Concluzii

Facand research pe internet pentru acest proiect, am observat ca exista foarte multe metode de prezicere a datasetului.

Consider ca am invatat multe lucruri interesante si cunostinte ce m-au ajutat, pentru ca tema aleasa m-a facut sa fiu curioasa si sa aflu mai multe moduri de prezicere, rezolvare a problemei.

Desi complexitatea rezolvarii este una foarte mica, slaba, consider totusi ca m-a ajutat sa acumulez mai multe informatii despre partea de prezicere, obtinere a unor statistici si a unei acurateti cat mai optime.